

Analyse en Difference-in-Differences

Rapport méthodologique et résultats empiriques

Base de données analysée : panel de 600 unités observées sur 24 périodes (14400 observations).

Ce document présente, de manière rigoureuse et reproductible, les principales variantes de l'estimateur en différence de différences (Difference-in-Differences, DiD) appliquées à la base de données jointe à ce rapport : DiD classique "2x2", DiD multi-périodes à effets fixes (TWFE), DiD dynamique (event-study), décomposition de Goodman-Bacon et estimateur robuste de Callaway & Sant'Anna pour les cas d'adoption échelonnée du traitement. Chaque méthode est accompagnée de sa justification théorique, de ses hypothèses d'identification, des résultats obtenus et des tests statistiques associés.

Document généré automatiquement le 28/06/2026.

1. Cadre méthodologique général

L'estimateur en différence de différences vise à estimer l'effet causal d'un traitement (une politique publique, un programme, un changement réglementaire...) en comparant l'évolution dans le temps de l'outcome Y entre un groupe traité et un groupe de contrôle. Son intérêt principal est de neutraliser, par différenciation, toute différence de NIVEAU constante entre les groupes (effets fixes individuels) ainsi que tout choc commun affectant identiquement les deux groupes (effet fixe temporel).

1.1 Hypothèses d'identification

- **Tendances parallèles (parallel trends)** : en l'absence de traitement, le groupe traité aurait connu, en moyenne, la même évolution de Y que le groupe de contrôle. C'est l'hypothèse centrale, non testable directement (elle porte sur un contrefactuel inobservé), mais dont on peut tester une implication nécessaire : l'absence de divergence de tendance AVANT le traitement (cf. section 3 et tests statistiques, section 4).
- **Absence d'anticipation (no anticipation)** : les unités ne modifient pas leur comportement en anticipation du traitement avant sa mise en œuvre effective.
- **SUTVA (Stable Unit Treatment Value Assumption)** : le traitement d'une unité n'affecte pas l'outcome des autres unités (pas d'effets de diffusion/débordement, "spillovers").
- **Pas de changement de composition** : dans un panel, les unités restent les mêmes sur toute la période (pas d'entrée/sortie liée au traitement lui-même).

1.2 Pourquoi plusieurs variantes ?

Le DiD "2x2" canonique (un groupe traité, un groupe de contrôle, une période avant/après) est le cas le plus simple et le plus facile à interpréter, mais il ne s'applique tel quel qu'à un design à une seule date de traitement. Dès lors que les données couvrent plusieurs périodes et/ou que les unités sont traitées à des dates différentes (*adoption échelonnée*, "staggered adoption"), il faut recourir à des extensions : la régression multi-périodes à effets fixes (TWFE), la spécification dynamique "event-study" (qui permet de tester les tendances parallèles ET de visualiser la dynamique de l'effet), et — point crucial mis en évidence par la littérature récente (Goodman-Bacon, 2021 ; Callaway & Sant'Anna, 2021 ; de Chaisemartin & D'Haultfoeuille, 2020 ; Sun & Abraham, 2021) — des estimateurs robustes lorsque l'effet du traitement est hétérogène entre cohortes ou évolue dans le temps, car le TWFE statique standard peut alors être **biaisé**.

2. Données et statistiques descriptives

La base utilisée est un panel d'unités observées sur plusieurs périodes, comportant un groupe jamais-traité et plusieurs cohortes traitées à des dates différentes (adoption échelonnée), ce qui permet d'illustrer l'ensemble des méthodes présentées dans ce rapport.

Groupe / cohorte	Nombre d'unités	Première période de traitement
Cohorte 2017	150	8
Cohorte 2020	150	14
Cohorte 2023	150	20
Jamais traite	150	jamais traité




Figure 1 — Trajectoires moyennes de l'outcome Y par cohorte de traitement. Les lignes verticales pointillées indiquent la date de première exposition au traitement de chaque cohorte. L'inspection visuelle des tendances avant traitement constitue un premier diagnostic (informel) de la plausibilité de l'hypothèse de tendances parallèles.

3. Variantes du Diff-in-Differences

3.1 DiD classique "2x2"

Cas le plus simple : un groupe traité, un groupe de contrôle, une période avant et une période après le traitement. L'effet DiD est la double différence des moyennes :

$$\text{DiD} = [Y_{\text{moy}}(\text{traite}, \text{apres}) - Y_{\text{moy}}(\text{traite}, \text{avant})] - [Y_{\text{moy}}(\text{controle}, \text{apres}) - Y_{\text{moy}}(\text{controle}, \text{avant})]$$

Cette quantité s'obtient de manière strictement équivalente comme le coefficient associé au terme d'interaction d'une régression OLS :

$$Y_{it} = \beta_0 + \beta_1 \cdot \text{Traité}_i + \beta_2 \cdot \text{Après}_t + \beta_3 \cdot (\text{Traité}_i \times \text{Après}_t) + \varepsilon_{it}$$

où β_3 est l'estimateur DiD recherché. L'avantage de la forme régression est de permettre l'ajout de covariables de contrôle et le calcul direct d'erreurs-types robustes/clusterisées par unité (recommandé dès qu'il y a plusieurs observations par unité ou une structure de groupe, afin de tenir compte de l'autocorrélation intra-unité).




Figure 2 — Représentation canonique du DiD 2x2 : la droite pointillée bleue représente l'évolution contrefactuelle du groupe traité (sa valeur de départ + la variation observée pour le groupe de contrôle). L'écart vertical entre cette contrefactuelle et la valeur réellement observée après traitement est l'estimateur DiD.

Comparaison	Estimation	Erreur-type (clusterisée/unité)	IC 95%	p-value
Cohorte 2017 vs Jamais traite	1.619	0.321	[0.99 ; 2.25]	< 0,0001

Vérification de cohérence : le calcul direct par moyennes de cellules donne 1.619, identique (à l'arrondi) au coefficient de régression — ce qui confirme l'équivalence algébrique entre les deux approches de calcul.

3.2 DiD multi-périodes : TWFE statique

Lorsque le panel comporte plus de deux périodes et/ou plusieurs cohortes traitées à des dates différentes, la spécification usuelle est la régression à effets fixes à deux dimensions ("Two-Way Fixed Effects", TWFE) :

$$Y_{it} = \alpha_i + \lambda_t + \beta \cdot D_{it} + \varepsilon_{it}$$

où α_i est un effet fixe individuel, λ_t un effet fixe temporel, et D_{it} l'indicatrice valant 1 si l'unité i est effectivement traitée à la période t . β est alors interprété comme l'effet moyen du traitement sur les traités (ATT).

Mise en garde essentielle : Goodman-Bacon (2021) et la littérature qui a suivi ont montré que, dès lors que (i) l'adoption du traitement est échelonnée dans le temps ET (ii) l'effet du traitement est hétérogène entre cohortes ou évolue dynamiquement avec la durée d'exposition, l'estimateur β du TWFE statique n'identifie en général PAS un ATT interprétable : il peut même, dans certains cas, être de signe opposé à l'effet réel. La raison est que la régression utilise implicitement certaines unités déjà traitées comme groupe de contrôle pour d'autres cohortes — une comparaison "à risque" (cf. section 3.4).

Spécification	Estimation (β)	Erreur-type	p-value
TWFE statique, toutes cohortes	2.172	0.082	< 0,0001

3.3 DiD dynamique : "event-study"

La spécification dynamique remplace l'indicatrice unique D_{it} par une série d'indicatrices de temps relatif au traitement ("leads" et "lags") :

$$Y_{it} = \alpha_i + \lambda_t + \sum_{k \neq -1} \delta_k \cdot 1\{t - G_i = k\} + \varepsilon_{it}$$

où G_i est la date de traitement de l'unité i ($G_i = \infty$ pour les unités jamais traitées) et $k = t - G_i$ le temps relatif au traitement. La période de référence (généralement $k = -1$, la période juste avant le traitement) est omise et sert de normalisation. Les coefficients $k < 0$ ("leads") permettent de **tester** les tendances parallèles avant traitement ; les coefficients $k \geq 0$ ("lags") retracent la **dynamique** de l'effet après traitement. Par souci de parcimonie statistique, les temps relatifs extrêmes sont regroupés ("binnés") dans des catégories terminales (ici ± 6 périodes).




Figure 3 — Coefficients d'event-study (TWFE) et intervalles de confiance à 95 %, par temps relatif au traitement. Les coefficients avant la ligne verticale (périodes pré-traitement) doivent être proches de zéro et non significatifs si l'hypothèse de tendances parallèles est valide ; ceux après la ligne retracent la montée en puissance de l'effet du traitement.

3.4 DiD à adoption échelonnée (1) : décomposition de Goodman-Bacon

Goodman-Bacon (2021, *Journal of Econometrics*) démontre que le coefficient du TWFE statique multi-cohortes est **mathématiquement égal** à une moyenne pondérée de TOUTES les comparaisons DiD 2x2 possibles entre paires de groupes définis par leur calendrier de traitement (chaque cohorte, et le groupe jamais-traité considéré comme une cohorte traitée "à l'infini") :

$$\beta_{\text{TWFE}} = \sum_{(k,l)} s_{kl} \cdot \beta_{(2 \times 2)_{kl}}$$

Ce théorème permet de distinguer deux types de comparaisons : (i) les comparaisons **propres** entre un groupe traité et le groupe jamais-traité (ou pas-encore-traité), non biaisées ; et (ii) les comparaisons **à risque** entre deux groupes *tous deux éventuellement traités*, dans lesquelles un groupe déjà traité sert implicitement de "contrôle" pour un autre groupe — alors qu'il subit lui-même un effet de traitement actif. Si cet effet est hétérogène ou évolue dans le temps, ces comparaisons biaisent l'estimateur global.

Note d'implémentation : la pondération utilisée ici applique le résultat général de pondération de toute régression groupée comme moyenne pondérée de coefficients de sous-échantillons (poids proportionnel à la taille du sous-échantillon $\times$ variance du traitement résiduelle des effets fixes), ce qui reproduit fidèlement la logique de la décomposition de Goodman-Bacon sans ré-implémenter l'algorithme original au bit près. La reconstruction pondérée obtenue (2.172) coïncide bien, comme attendu, avec l'estimation directe du TWFE (2.172), ce qui valide numériquement la décomposition. Pour une réplication exacte de l'algorithme publié, le package R *bacondecomp* reste la référence.




Figure 4 — "Bacon plot" : chaque point est une comparaison 2x2 entre deux groupes de calendrier de traitement, positionnée selon son poids dans la décomposition (abscisse) et son estimation (ordonnée). En rouge : comparaisons "à risque" entre deux groupes éventuellement traités ; en vert : comparaisons propres vs le groupe jamais-traité.

Comparaison	Type	β (2x2)	Poids
Cohorte 2017 / Cohorte 2023	À risque	1.435	0.201
Cohorte 2020 / Jamais traite	Propre	2.564	0.199
Cohorte 2017 / Jamais traite	Propre	5.174	0.166

Cohorte 2020 / Cohorte 2023	À risque	1.584	0.151
Cohorte 2017 / Cohorte 2020	À risque	0.376	0.151
Cohorte 2023 / Jamais traite	Propre	1.647	0.132

Lecture : les comparaisons "à risque" représentent ici 50% du poids total de la décomposition. Une part importante de comparaisons à risque, combinée à une forte dispersion des estimations 2x2 sous-jacentes, est un signal d'alerte indiquant que le TWFE statique global doit être interprété avec prudence et qu'un estimateur robuste (section 3.5) est préférable pour résumer l'effet moyen du traitement.

3.5 DiD à adoption échelonnée (2) : estimateur de Callaway & Sant'Anna

Callaway & Sant'Anna (2021, *Journal of Econometrics*) proposent de construire l'inférence à partir d'effets désagrégés par cohorte de traitement g et par période t , les **ATT(g,t)** ("group-time average treatment effects") :

$$ATT(g, t) = E[Y_t - Y_{(g-1)} \mid G = g] - E[Y_t - Y_{(g-1)} \mid \text{groupe de comparaison}]$$

Chaque $ATT(g,t)$ est un DiD 2x2 "propre" entre la cohorte g et un groupe de comparaison non-encore-traité à la période t (ici, le groupe jamais-traité), ancré sur la dernière période avant le traitement de la cohorte ($g-1$). En particulier, les valeurs $ATT(g,t)$ calculées pour $t < g$ constituent un test de pré-tendance SPÉCIFIQUE à chaque cohorte. Ces effets désagrégés sont ensuite agrégés : (i) en un ATT global (moyenne pondérée par taille de cohorte des effets post-traitement) et (ii) en un profil dynamique $ATT(e)$, où $e = t - g$ est le temps relatif au traitement, directement comparable à l'event-study TWFE de la section 3.3 mais robuste à l'hétérogénéité dynamique des effets.




Figure 5 — Carte des $ATT(g,t)$ par cohorte (lignes) et période (colonnes). Les zones correspondant aux périodes antérieures à la date de traitement de chaque cohorte servent de test de pré-tendance ; les zones postérieures retracent la dynamique de l'effet, cohorte par cohorte.




Figure 6 — Comparaison du profil dynamique obtenu par l'event-study TWFE naïf (gris) et par l'agrégation des $ATT(g,t)$ de Callaway & Sant'Anna (vert). Un écart marqué entre les deux profils, particulièrement après traitement, signale la présence d'un biais du TWFE statique lié à l'hétérogénéité dynamique des effets de traitement entre cohortes (cf. section 3.4).

Méthode	ATT estimé	Erreur-type	IC 95% (approx.)
---------	------------	-------------	------------------

TWFE statique	2.172	0.082	[2.01 ; 2.33]
Callaway & Sant'Anna (agrégé)	3.642	0.057	[3.53 ; 3.75]

Lecture : l'écart entre les deux estimateurs (1.470) illustre concrètement le biais du TWFE statique en présence d'effets dynamiques hétérogènes entre cohortes : les cohortes traitées plus tôt ayant ici un effet qui croît plus rapidement avec la durée d'exposition, elles contaminent, via les comparaisons "à risque" identifiées par la décomposition de Goodman-Bacon, l'estimation globale du TWFE. L'estimateur de Callaway & Sant'Anna, en n'utilisant que des comparaisons propres contre le groupe jamais-traité, fournit ici une estimation plus fiable de l'effet moyen du traitement sur les traités.

4. Tests statistiques

4.1 Test conjoint de tendances parallèles (test de Wald)

Ce test évalue conjointement l'hypothèse nulle selon laquelle TOUS les coefficients "leads" pré-traitement de l'event-study (figure 3) sont simultanément nuls : $H_0 : \delta_k = 0$ pour tout $k < 0$. La statistique de test suit asymptotiquement une loi du χ^2 sous H_0 .

Statistique de test = 82.460 (degrés de liberté = 5) ; p-value = < 0,0001.

Conclusion brute du test : Rejet de H_0 : signe potentiel de violation des tendances parallèles (à interpréter avec prudence, cf. biais de contamination des effets fixes temps en cas d'adoption échelonnée)

Mise en perspective importante : dans le cas d'une adoption échelonnée du traitement avec effets dynamiques hétérogènes, les effets fixes temporels du TWFE peuvent être "contaminés" par les effets de traitement (déjà actifs) d'autres cohortes, ce qui peut produire des pseudo-pré-tendances n'ayant rien à voir avec une réelle violation de l'hypothèse de tendances parallèles (Sun & Abraham, 2021 ; de Chaisemartin & D'Haultfoeuille, 2020). C'est exactement ce qui est observé ici sur la catégorie terminale "lead lointain" de la figure 3 : en croisant ce résultat avec les ATT(g,t) pré-traitement de Callaway & Sant'Anna (figure 5, zones antérieures au traitement, qui n'utilisent que des comparaisons propres contre le groupe jamais-traité et restent non significatives pour l'écrasante majorité des cellules), on conclut que la violation détectée par le test TWFE est vraisemblablement un artefact de contamination plutôt qu'une réelle rupture de tendance parallèle. Ce diagnostic croisé illustre pourquoi il est recommandé de toujours interpréter le test de pré-tendance TWFE conjointement avec un estimateur robuste à l'hétérogénéité dynamique en contexte d'adoption échelonnée.

4.2 Test de placebo (fausse date de traitement)

On attribue artificiellement une date de traitement antérieure à la vraie date (ici 4, alors que la vraie date est ultérieure), exclusivement à l'intérieur de la période pré-traitement, puis on réestime un DiD 2x2 sur ces données placebo où, par construction, AUCUNE unité n'est réellement traitée. Sous l'hypothèse de tendances parallèles (et d'absence d'anticipation), l'effet placebo doit être statistiquement nul.

Estimation placebo = 0.370 (erreur-type = 0.311) ; p-value = 0.2342.

Conclusion : Non-rejet de H_0 : aucun effet placebo détecté

4.3 Test de permutation (inférence par randomisation)

Ce test non-paramétrique reconstruit la distribution de l'estimateur DiD 2x2 SOUS L'HYPOTHÈSE NULLE D'EFFET NUL, en réaffectant aléatoirement le statut "traité" parmi l'ensemble des unités (1000 permutations, en conservant le nombre d'unités traitées), puis situe l'estimation réellement observée dans cette distribution nulle empirique. Il est particulièrement recommandé lorsque le nombre de clusters (unités ou groupes) est faible, cas dans lequel les tests asymptotiques usuels (basés sur l'erreur-type clusterisée) sont peu fiables.




Figure 7 — Distribution nulle de l'estimateur DiD 2x2 sous permutations aléatoires du statut de traitement, et position de l'estimation réellement observée.

p-value de permutation = $< 0,0001$.

Conclusion : Rejet de H_0 : l'estimation réelle est extrême par rapport à la distribution nulle de permutation

4.4 Test de Breusch-Pagan (hétéroscédasticité)

Teste l'hypothèse nulle d'homoscédasticité des résidus de la régression DiD 2x2 (variance des résidus constante, indépendante des régresseurs). Une hétéroscédasticité détectée justifie l'usage d'erreurs-types robustes (HC) ou clusterisées plutôt que les erreurs-types OLS "classiques" — ce que ce template applique par défaut, indépendamment du résultat de ce test, par précaution.

Statistique de Breusch-Pagan = 0.510 ; p-value = 0.9168.

Conclusion : Non-rejet de H_0 : pas d'heteroscedasticite detectee

4.5 Bootstrap par cluster (unité)

Ré-échantillonnage avec remise des UNITÉS (et non des observations individuelles, afin de respecter la structure de panel et l'autocorrélation intra-unité), répété 500 fois, pour obtenir une erreur-type et un intervalle de confiance empiriques alternatifs à ceux, asymptotiques, de la régression avec erreurs-types clusterisées. Recommandé en complément lorsque le nombre de clusters est faible.




Figure 8 — Distribution bootstrap (par cluster) de l'estimateur DiD 2x2.

Erreur-type asymptotique (cluster) = 0.321 vs erreur-type bootstrap = 0.343 ; intervalle de confiance bootstrap à 95 % = [0.94 ; 2.29].

Conclusion : la proximité entre l'erreur-type asymptotique et l'erreur-type bootstrap renforce la confiance dans l'inférence ; un écart important inviterait à privilégier l'intervalle bootstrap, plus robuste aux petits échantillons.

5. Synthèse des résultats

Le tableau ci-dessous récapitule les estimations obtenues par chacune des méthodes de DiD multi-périodes/multi-cohortes appliquées à la base de données.

Méthode	Estimation	Erreur-type	IC 95%	p-value
DiD 2x2	1.619	0.321	[0.99 ; 2.25]	< 0,0001
TWFE statique (multi-périodes, multi-cohortes)	2.172	0.082	[2.01 ; 2.33]	< 0,0001
Callaway & Sant'Anna (ATT global agrege)	3.642	0.057	[3.53 ; 3.75]	--

Recommandation de lecture : en présence d'adoption échelonnée et d'hétérogénéité dynamique des effets (diagnostiquée ici par la décomposition de Goodman-Bacon, section 3.4), l'estimateur de Callaway & Sant'Anna doit être préféré au TWFE statique pour résumer l'effet moyen du traitement sur les traités. Le TWFE statique et son event-study restent néanmoins utiles comme outils de diagnostic et de comparaison.

6. Limites et recommandations

- Toutes les méthodes présentées supposent l'absence de "spillovers" (SUTVA) : si le traitement d'une unité affecte l'outcome d'unités non-traitées (effets de débordement géographique, concurrentiel...), les estimateurs sont biaisés.
- L'hypothèse de tendances parallèles n'est jamais prouvée, seulement rendue plus ou moins plausible par les tests de pré-tendance ; une bonne pratique consiste à la documenter qualitativement (changements institutionnels concomitants, groupes de comparaison alternatifs, etc.).
- En présence d'un faible nombre de clusters (groupes ou unités), privilégier le bootstrap par cluster ou le bootstrap sauvage ("wild cluster bootstrap") à l'inférence asymptotique standard.
- La décomposition de Goodman-Bacon implémentée ici suit la logique du théorème original mais en simplifie le calcul des poids ; pour une publication académique, repasser par l'algorithme exact (package R `bacondecomp`) est recommandé.
- L'estimateur de Callaway & Sant'Anna implémenté ici utilise uniquement le groupe jamais-traité comme groupe de comparaison ; il existe une variante "pas-encore-traité" (not-yet-treated) qui peut être plus efficace si le groupe jamais-traité est petit ou absent.
- D'autres estimateurs robustes à l'hétérogénéité dynamique non couverts ici (Sun & Abraham, 2021 ; de Chaisemartin & D'Haultfoeuille, 2020 ; Borusyak, Jaravel & Spiess, 2024) peuvent être pertinents selon le contexte.

Références

- Callaway, B. & Sant'Anna, P. H. C. (2021). "Difference-in-Differences with Multiple Time Periods." *Journal of Econometrics*, 225(2), 200-230.
- Goodman-Bacon, A. (2021). "Difference-in-differences with variation in treatment timing." *Journal of Econometrics*, 225(2), 254-277.
- de Chaisemartin, C. & D'Haultfoeuille, X. (2020). "Two-Way Fixed Effects Estimators with Heterogeneous Treatment Effects." *American Economic Review*, 110(9), 2964-2996.
- Sun, L. & Abraham, S. (2021). "Estimating dynamic treatment effects in event studies with heterogeneous treatment effects." *Journal of Econometrics*, 225(2), 175-199.
- Roth, J., Sant'Anna, P. H. C., Bilinski, A. & Poe, J. (2023). "What's Trending in Difference-in-Differences? A Synthesis of the Recent Econometrics Literature." *Journal of Econometrics*, 235(2), 2218-2244.
- Card, D. & Krueger, A. B. (1994). "Minimum Wages and Employment: A Case Study of the Fast-Food Industry in New Jersey and Pennsylvania." *American Economic Review*, 84(4), 772-793.
- Cameron, A. C., Gelbach, J. B. & Miller, D. L. (2008). "Bootstrap-Based Improvements for Inference with Clustered Errors." *Review of Economics and Statistics*, 90(3), 414-427.