

Fondements mathématiques des tests statistiques du diagnostic OLS

Fiche d'accompagnement du script `ols_analysis_template.py`

1. Cadre général : le modèle linéaire et les hypothèses de Gauss-Markov

On considère le modèle linéaire

$$y = X\beta + \varepsilon, \quad y \in \mathbb{R}^n, \quad X \in \mathbb{R}^{n \times k}, \quad \beta \in \mathbb{R}^k, \quad \varepsilon \in \mathbb{R}^n,$$

estimé par les moindres carrés ordinaires (OLS) :

$$\hat{\beta} = (X^\top X)^{-1} X^\top y, \quad \hat{\varepsilon} = y - X\hat{\beta}, \quad \hat{y} = X\hat{\beta}.$$

L'estimateur OLS est BLUE (*Best Linear Unbiased Estimator*, théorème de Gauss-Markov) sous les hypothèses suivantes, que chaque test de ce document vise à vérifier empiriquement :

(H1) **Exogénéité** : $\mathbb{E}[\varepsilon \mid X] = 0$.

(H2) **Homoscédasticité** : $\text{Var}(\varepsilon_i \mid X) = \sigma^2$ pour tout i (constante).

(H3) **Absence d'autocorrélation** : $\text{Cov}(\varepsilon_i, \varepsilon_j \mid X) = 0$ pour $i \neq j$.

(H4) **Rang plein** : $\text{rang}(X) = k$ (pas de colinéarité parfaite entre régresseurs).

(H5) **Normalité** (optionnelle, requise pour l'inférence *exacte* en petit échantillon) : $\varepsilon \mid X \sim \mathcal{N}(0, \sigma^2 I_n)$.

(H6) **Spécification correcte** : la vraie relation entre $\mathbb{E}[y \mid X]$ et X est linéaire en β .

La matrice de variance-covariance de $\hat{\beta}$ sous (H1)–(H3) est $\text{Var}(\hat{\beta} \mid X) = \sigma^2 (X^\top X)^{-1}$, estimée par $\hat{\sigma}^2 (X^\top X)^{-1}$ avec $\hat{\sigma}^2 = \hat{\varepsilon}^\top \hat{\varepsilon} / (n - k)$. C'est cette matrice que la violation de (H2) ou (H3) rend invalide, et que les erreurs-types robustes (section 8) corrigent.

2. Tests sur les coefficients individuels et test F global

2.1 Test de Student sur un coefficient

Sous (H1)–(H5), pour chaque coefficient β_j :

$$T_j = \frac{\hat{\beta}_j - \beta_j^0}{\widehat{\text{se}}(\hat{\beta}_j)} \sim t_{n-k} \quad \text{sous } H_0 : \beta_j = \beta_j^0,$$

où $\widehat{\text{se}}(\hat{\beta}_j) = \hat{\sigma} \sqrt{[(X^\top X)^{-1}]_{jj}}$. C'est la statistique `t` et la `P > |t|` affichées dans `model.summary()`.

2.2 Test F de significativité globale

Pour tester $H_0 : \beta_1 = \dots = \beta_{k-1} = 0$ (tous les coefficients hors constante sont nuls) :

$$F = \frac{R^2 / (k - 1)}{(1 - R^2) / (n - k)} \sim F_{k-1, n-k} \quad \text{sous } H_0.$$

C'est le **F-statistic** et **Prob (F-statistic)** du résumé `statsmodels`.

3. Normalité des résidus

3.1 Test de Jarque-Bera

Définition 1. Soient le coefficient d'asymétrie (skewness) et l'aplatissement (kurtosis) empiriques des résidus :

$$\hat{S} = \frac{\frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^3}{\hat{\sigma}^3}, \quad \hat{K} = \frac{\frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^4}{\hat{\sigma}^4}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^2.$$

La statistique de Jarque-Bera est

$$JB = \frac{n}{6} \left(\hat{S}^2 + \frac{(\hat{K} - 3)^2}{4} \right).$$

Hypothèse testée : H_0 : les résidus suivent une loi normale (sous H_0 , $\hat{S} \rightarrow 0$ et $\hat{K} \rightarrow 3$). **Distribution asymptotique :** $JB \xrightarrow{d} \chi_2^2$ sous H_0 . **Décision :** on rejette H_0 si $JB > \chi_{2,1-\alpha}^2$, équivalent à $p < \alpha$.

3.2 Test de Shapiro-Wilk

Définition 2. Soit $\hat{\varepsilon}_{(1)} \leq \dots \leq \hat{\varepsilon}_{(n)}$ les résidus ordonnés. La statistique de Shapiro-Wilk est

$$W = \frac{\left(\sum_{i=1}^n a_i \hat{\varepsilon}_{(i)} \right)^2}{\sum_{i=1}^n (\hat{\varepsilon}_i - \bar{\hat{\varepsilon}})^2},$$

où les coefficients (a_i) sont calculés à partir des espérances et de la matrice de covariance des statistiques d'ordre d'un échantillon gaussien standard : $a = \frac{m^\top V^{-1}}{(m^\top V^{-1} V^{-1} m)^{1/2}}$, avec m le vecteur des espérances des statistiques d'ordre et V leur matrice de covariance.

Hypothèse testée : H_0 : normalité des résidus. W est proche de 1 sous H_0 et diminue en présence d'écarts à la normalité ; on rejette H_0 pour de petites valeurs de W (table ou p -valeur calculée numériquement, pas de forme close simple).

4. Homoscédasticité

4.1 Test de Breusch-Pagan

Définition 3. On estime la régression auxiliaire des résidus au carré sur les régresseurs :

$$\hat{\varepsilon}_i^2 = \delta_0 + \delta_1 x_{i1} + \dots + \delta_p x_{ip} + u_i,$$

et on note R_{aux}^2 le coefficient de détermination de cette régression.

La statistique du multiplicateur de Lagrange est

$$LM = n \cdot R_{aux}^2 \xrightarrow{d} \chi_p^2 \quad \text{sous } H_0 : \delta_1 = \dots = \delta_p = 0,$$

où p est le nombre de régresseurs de l'équation auxiliaire (hors constante). **Hypothèse testée :** H_0 : homoscédasticité ($\text{Var}(\varepsilon_i | X)$ ne dépend pas de X_i). Le test suppose implicitement que les résidus restent approximativement gaussiens (sensibilité connue à la non-normalité).

4.2 Test de White

Généralisation du test de Breusch-Pagan : la régression auxiliaire inclut en plus les carrés et produits croisés des régresseurs :

$$\hat{\varepsilon}_i^2 = \delta_0 + \sum_j \delta_j x_{ij} + \sum_j \gamma_j x_{ij}^2 + \sum_{j < l} \theta_{jl} x_{ij} x_{il} + u_i.$$

La statistique est identique en forme : $LM = n \cdot R_{\text{aux}}^2 \xrightarrow{d} \chi_q^2$, où q est le nombre total de régresseurs de cette équation augmentée. **Avantage** sur Breusch-Pagan : détecte des formes d'hétéroscédasticité non linéaires dans les régresseurs, sans imposer de forme paramétrique particulière à $\text{Var}(\varepsilon_i | X)$. **Coût** : perte de puissance en petit échantillon du fait du nombre accru de paramètres estimés ($q > p$).

5. Autocorrélation des résidus

5.1 Statistique de Durbin-Watson

$$DW = \frac{\sum_{t=2}^n (\hat{\varepsilon}_t - \hat{\varepsilon}_{t-1})^2}{\sum_{t=1}^n \hat{\varepsilon}_t^2}.$$

Propriété 1. En développant le numérateur, $DW \approx 2(1 - \hat{\rho})$, où $\hat{\rho} = \frac{\sum_{t=2}^n \hat{\varepsilon}_t \hat{\varepsilon}_{t-1}}{\sum_{t=1}^n \hat{\varepsilon}_t^2}$ est l'autocorrélation empirique d'ordre 1 des résidus.

Lecture : $DW \in [0, 4]$. $DW \approx 2 \Leftrightarrow \hat{\rho} \approx 0$ (pas d'autocorrélation) ; $DW \rightarrow 0 \Leftrightarrow \hat{\rho} \rightarrow 1$ (autocorrélation positive forte) ; $DW \rightarrow 4 \Leftrightarrow \hat{\rho} \rightarrow -1$ (autocorrélation négative). La distribution exacte de DW sous H_0 dépend de X ; on utilise des bornes tabulées (d_L, d_U) plutôt qu'une loi unique. Le test est surtout pertinent pour des données ordonnées dans le temps ou l'espace (séries temporelles, panels) ; sur des données en coupe sans ordre naturel comme Iris, son interprétation est purement illustrative.

5.2 Test de Ljung-Box

Définition 4. Soit $\hat{\rho}_k = \frac{\sum_{t=k+1}^n \hat{\varepsilon}_t \hat{\varepsilon}_{t-k}}{\sum_{t=1}^n \hat{\varepsilon}_t^2}$ l'autocorrélation empirique d'ordre k des résidus. La statistique de Ljung-Box jusqu'à l'ordre h est

$$Q_h = n(n+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n-k}.$$

Hypothèse testée : $H_0 : \rho_1 = \dots = \rho_h = 0$ (absence d'autocorrélation jusqu'à l'ordre h).

Distribution asymptotique : $Q_h \xrightarrow{d} \chi_h^2$ sous H_0 . Contrairement à Durbin-Watson, ce test teste conjointement plusieurs ordres d'autocorrélation et fournit une p -valeur exacte sans recourir à des bornes tabulées.

6. Multicolinéarité : le facteur d'inflation de la variance (VIF)

Définition 5. Pour chaque régresseur X_j , on estime la régression de X_j sur tous les autres régresseurs (avec constante) :

$$X_j = \gamma_0 + \sum_{l \neq j} \gamma_l X_l + u,$$

et on note R_j^2 le coefficient de détermination de cette régression. Le facteur d'inflation de la variance est

$$\text{VIF}_j = \frac{1}{1 - R_j^2}.$$

Propriété 2. VIF_j mesure directement à quel point la variance de $\hat{\beta}_j$ est inflatée par la corrélation de X_j avec les autres régresseurs :

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{(n-1) \text{Var}(X_j)} \times VIF_j.$$

Lecture : $VIF_j = 1$ si X_j est orthogonal aux autres régresseurs (aucune inflation). En pratique, $VIF_j > 5$ (ou 10 selon les conventions) signale une colinéarité préoccupante : les écarts-types des coefficients concernés sont gonflés, ce qui dégrade la précision de l'inférence sans biaiser $\hat{\beta}$ en espérance.

7. Spécification du modèle : test RESET de Ramsey

Définition 6. On augmente le modèle initial avec des puissances des valeurs ajustées $\hat{y}_i = x_i^\top \hat{\beta}$:

$$y_i = x_i^\top \beta + \delta_2 \hat{y}_i^2 + \delta_3 \hat{y}_i^3 + \cdots + \delta_m \hat{y}_i^m + \eta_i.$$

Hypothèse testée : $H_0 : \delta_2 = \cdots = \delta_m = 0$ (le modèle linéaire initial est correctement spécifié ; aucune non-linéarité systématique n'est omise). **Statistique :** un test F classique de restrictions linéaires conjointes,

$$F = \frac{(SSR_0 - SSR_1)/q}{SSR_1/(n-k-q)} \sim F_{q, n-k-q} \text{ sous } H_0,$$

où SSR_0 et SSR_1 sont les sommes des carrés des résidus du modèle restreint (initial) et non restreint (augmenté), et $q = m - 1$ le nombre de termes ajoutés. **Interprétation d'un rejet :** la forme fonctionnelle linéaire est inadéquate — il manque des termes non linéaires (carrés, interactions) ou la relation devrait être transformée (log, etc.).

8. Erreurs-types robustes à l'hétéroscédasticité : l'estimateur HC3

8.1 Principe général (White, 1980)

Sous hétéroscédasticité, $\text{Var}(\hat{\beta} \mid X) = (X^\top X)^{-1} X^\top \Omega X (X^\top X)^{-1}$ avec $\Omega = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$ non constante. L'idée de White est d'estimer directement $X^\top \Omega X$ sans jamais estimer chaque σ_i^2 individuellement (ce qui serait infaisable avec n paramètres pour n observations), en utilisant les résidus au carré comme estimateurs (bruités mais sans biais asymptotique) des σ_i^2 :

$$\widehat{\text{Var}}_{\text{HC}}(\hat{\beta}) = (X^\top X)^{-1} X^\top \hat{\Omega} X (X^\top X)^{-1}, \quad \hat{\Omega} = \text{diag}(\hat{\omega}_1, \dots, \hat{\omega}_n).$$

8.2 Les variantes HC0 à HC3

Soit $h_{ii} = x_i^\top (X^\top X)^{-1} x_i$ le *levier* (*leverage*) de l'observation i , c'est-à-dire le i -ème élément diagonal de la matrice de projection $H = X(X^\top X)^{-1} X^\top$.

Variante	$\hat{\omega}_i$	Remarque
HC0 (White, 1980)	$\hat{\varepsilon}_i^2$	estimateur de base, biaisé en petit échantillon
HC1	$\frac{n}{n-k} \hat{\varepsilon}_i^2$	correction de degrés de liberté (facteur global)
HC2	$\frac{\hat{\varepsilon}_i^2}{1 - h_{ii}}$	correction par observation, exacte sous homoscedasticité
HC3	$\frac{\hat{\varepsilon}_i^2}{(1 - h_{ii})^2}$	pondération plus forte des points à fort levier

8.3 Pourquoi HC3 et pas HC1

HC3 approxime l'estimateur *jackknife* (delete-one) de la variance de $\hat{\beta}$: on peut montrer que

$$\hat{\beta}_{(-i)} - \hat{\beta} = -\frac{(X^\top X)^{-1} x_i \hat{\varepsilon}_i}{1 - h_{ii}},$$

où $\hat{\beta}_{(-i)}$ est l'estimateur obtenu en retirant l'observation i . Le terme en $(1 - h_{ii})^2$ de HC3 reproduit exactement le carré de ce facteur d'amplification, ce qui pénalise davantage les observations à fort levier — précisément celles pour lesquelles HC0 et HC1 sous-estiment le plus la variance réelle. C'est ce qui rend HC3 plus prudent (intervalles de confiance plus larges, donc plus conservateur) que HC0/HC1/HC2 en petit échantillon, au prix d'une perte de puissance si l'homoscédasticité est en réalité vérifiée.

8.4 Ce qui change concrètement

Les coefficients $\hat{\beta}$ sont **identiques** entre OLS classique et OLS avec erreurs-types HC3 : seule la matrice de variance-covariance change, donc seuls les écarts-types, statistiques z (et non plus t , car la distribution exacte sous H_0 n'est plus connue, seulement asymptotique) et p -valeurs sont recalculés.

9. Tableau récapitulatif

Test	H_0	Loi sous H_0	Fonction du script
Student (t)	$\beta_j = 0$	t_{n-k}	<code>model.summary()</code>
F global	tous $\beta_j = 0$ ($j \geq 1$)	$F_{k-1, n-k}$	<code>model.summary()</code>
Jarque-Bera	résidus normaux	χ^2_2	<code>jarque_bera</code>
Shapiro-Wilk	résidus normaux	—	<code>stats.shapiro</code>
		(table/numérique)	
Breusch-Pagan	homoscédasticité	χ^2_p	<code>het_breuschpagan</code>
White	homoscédasticité	χ^2_q	<code>het_white</code>
Durbin-Watson	$\rho_1 = 0$	bornes (d_L, d_U)	<code>durbin_watson</code>
Ljung-Box	$\rho_1 = \dots = \rho_h = 0$	χ^2_h	<code>acorr_ljungbox</code>
VIF	— (diagnostic, pas un test d'hypothèse)	—	<code>variance_inflation_factor</code>
RESET (Ramsey)	spécification correcte	$F_{q, n-k-q}$	<code>compare_f_test</code>
HC3	— (correction, pas un test)	—	<code>fit(cov_type="HC3")</code>

Note méthodologique : tous ces tests (hors VIF et HC3, qui sont des outils de diagnostic et de correction respectivement) reposent sur des statistiques asymptotiques (χ^2 , F) dont la validité en *petit* échantillon dépend elle-même des hypothèses (H1)–(H5) qu'ils cherchent à vérifier — un test de spécification n'est jamais une preuve absolue, seulement une indication statistique sous les hypothèses du test lui-même.